

# OpenGL-basiertes Software Occlusion Culling zur Beschleunigung des 3D-Renderings großer Datenmengen und komplexer Szenen

Projekt-Inf 3D-Rendering

Dominik Sellenthin

Christian Stegmaier

Gariharan Kanthasamy



Abb. 1. Links: Testergebnisbild nach einem erfolgreichen Durchlauf der OGL-Methode aus der verwendeten Intel-Testszene. Rote Linien um Objekte stellen die Axis Aligned Bounding Box des jeweiligen Objekts dar. Rechts: Bild aller Objekte, die beim Occlusion Culling als verdeckt klassifiziert wurden und im linken Bild nicht gerendert wurden.

## Kurzbeschreibung—

In Bereichen des 3D-Rendering, sei es in der wissenschaftlichen Visualisierung oder in Computerspielen, ist die Rechenleistung der Grafikkarte schnell an ihrer Grenze, während die CPU kaum in Anspruch genommen wird. Es werden daher Techniken benötigt, die den Aufwand beim Rendern so gering wie möglich halten und gleichzeitig der ständig zunehmenden Dynamik gerecht werden. Eine dieser Techniken ist das Software Occlusion Culling (SOC). Ziel des Occlusion Cullings ist es, komplett parallel zum GPU-Rendering des aktuellen Frames, festzustellen, welche Objekte in der kommenden Szene zu sehen sind und welche Objekte nicht gerendert werden müssen. Damit die GPU entlastet wird, ist es Wünschenswert, die Berechnungen des Occlusion Cullings auf die CPU auszulagern. Um das zu erreichen und um die vollständige Rechenleistung moderner Multi-Core CPUs zu gewährleisten, wird in dieser Arbeit ein bereits vorhandener Software-Rasterizer, Mesa 3D, verwendet, der zusätzlich die OpenGL API zur Verfügung stellt. In dieser Arbeit wird daher in einem von Intel entwickelten SOC-Framework eine auf Mesa-3D basierende Occlusion Culling Technik implementiert und folglich auf ihre Tauglichkeit mit bereits im Framework existierenden Techniken verglichen.

## 1 EINLEITUNG

Heutige Anwendungen haben immer höhere Ansprüche an die Leistung der Engines(?) und der Wunsch nach besserer Performance und höheren Bildraten (frames per second, FPS) ist groß. Hinzukommt, dass in modernen Anwendungen die zu rendernden Szenen immer weniger statisch und immer mehr dynamisch werden, wie es beispielsweise in Computerspielen der Fall ist. Um dieser Dynamik gerecht zu werden, wird sich von Verfahren mit potenziellen Sichtbarkeitsmengen entfernt [3] und es wird sich einer Methode namens *Occlusion Culling* (*to occlude* = verdecken, *to cull* = aussondern, herausfiltern) bedient. Ziel des Occlusion Cullings ist es, noch vor dem Rendering der nächsten Szene, herauszufinden, welche Objekte in der kommenden Szene sichtbar sind und welche nicht. Im Wesentlichen gilt es dabei zuerst mit einer ausgewählten Teilmenge der Objekte einen geeigneten Tiefenpuffer (Z-Buffer) zu generieren und darauffolgend mit Hilfe von Occlusion Queries alle Objekte zu bestimmen, die noch sichtbar sind (auch Z-Buffering oder Tiefentest genannt). Das Ergebnis der Occlusion Queries kann anschließend ohne nennenswerte Latenz verwendet werden, um der GPU mitzuteilen, welche Objekte gerendert werden sollen, so dass unnötiger Rechenaufwand der GPU vermieden wird.

CPU	OC Frame 0	OC Frame 1	OC Frame 2	OC Frame 3	...	OC Frame n
GPU	-	Render Frame 0	Render Frame 1	Render Frame 2	...	Render Frame n-1
Frame	0	1	2	3	...	n

Abb. 2. Während ein Frame gerendert wird, berechnet der Prozessor parallel zum Rendering bereits, welche Objekte in der nächsten Szene zu sehen sind.

Bei Anwendungen, die ohnehin schon enormen Rechenaufwand benötigen und die maximale Rechenkapazität der Grafikkarte schnell ausreizen, ist es schwierig den zusätzlichen Mehraufwand ebenfalls der Grafikkarte aufzuerlegen. Es bietet sich daher an, den Mehraufwand dem wenig genutzten Prozessor zu übergeben, der dann komplett parallel zur Grafikkarte das Occlusion Culling in einem Vorverarbeitungsschritt durchführen soll, siehe Abb. 2.

Moderne Prozessoren besitzen mittlerweile einige separat nutzbare Kerne, die parallel verwendet werden können, um das Occlusion Culling so effektiv und effizient wie möglich zu implementieren. Damit die gesamte Rechenleistung der Prozessoren auch genutzt wird, wird in dieser Arbeit auf den Software-Rasterizer Mesa 3D zurückgegriffen, der außerdem mit der bewährten OpenGL API arbeitet.




Abb. 3. Verwende größtenteils vorhandene Strukturen, um die verwendete Geometrie zu laden. Anschließend erfolgt das Culling durch die neue OGL-Culling-Methode. Zum Schluss wird die nicht gecullte Geometrie an das Framework zurückgegeben, damit das Ergebnis gerendert wird.

Implementiert wurde die OGL-Methode in einem Software Occlusion Culling (SOC) Framework, das von Intel frei zur Verfügung gestellt wird [1]. Das Framework eignet sich sehr gut für die Implementierung einer neuen SOC-Methode, da es sowohl essentielle Ablaufstrukturen als auch eine ausreichend große und komplexe Testszene zur Verfügung stellt, mit der eine Evaluation der OGL-Methode ermöglicht wird, siehe Abb. 1 links.

## 2 RELATED WORK

Diese Arbeit orientiert sich stark an Intels SOC-Framework, in das die in dieser Arbeit entwickelte OGL-Methode eingebettet wurde. Da das Framework bereits alle notwendigen Strukturen für schon bestehende Methoden besitzt (siehe Abb. 3), gestaltet sich die Erweiterung um eine weitere Methode größtenteils unkompliziert. Hinzukommen lediglich Veränderungen der Routinen zum Laden der Testszene und die Implementierung des Cullings selber. Vorhanden sind unter anderem Methoden, die mit *Streaming SIMD Extension* (SSE) und *Intel Advanced Vector Extension* (AVX) arbeiten. Außerdem ist noch eine optimierte Variante der AVX-Technik vorhanden, *Masked Software Occlusion Culling* (MSOC) [3], die mit einer abgewandelten Form des hierarchischen Z-Buffers (HiZ) [2] arbeitet, der durch einen Software-Rasterisierer berechnet wird.

Hasselgren et al. [3] stellen in ihrer Arbeit einen Algorithmus vor, der durch seinen effizienten HiZ die Performanz signifikant verbessert. Anstatt wie früheren Arbeiten Pixel als kleinste Einheit zu betrachten, werden nun *Kacheln* verwendet. Kacheln sind dabei lediglich eine Zusammenfassung mehrerer aneinanderliegender Pixel. Da AVX2 ermöglicht, 8 SIMD Instruktionen mit 32-Bit Präzision auszuführen, wurde für die Kacheln eine Größe von 32x8 Pixeln gewählt. Indem Bitmasken von rechts und links in die Kacheln geschoben werden, wird am Ende eine Abdeckungsmaske erhalten, die angibt, welche Pixel in einer Kachel verdeckt werden [3]. Während ihr Algorithmus keine 100% Präzision garantiert - *false positives* sind möglich - bewegt sich der Fehler in gleicher Größenordnung wie bei bisherigen Algorithmen. Ein wichtiger Faktor für die Performanz ihres Algorithmus ist die Reihenfolge, in der die Objekte gerendert werden. Die Objekte sollten bestmöglichst von vorne nach hinten gerendert werden. Dadurch werden die wichtigsten Occluder als erstes rasterisiert (dargestellt) und für den Fall, dass die Zeit für Occlusion Culling begrenzt ist, wird trotzdem ein nahezu optimales Ergebnis erzielt [3].

Bei einem Vergleich zwischen einem HiZ-Algorithmus und dem MSOC - bei voller Auflösung (1920x1080 Pixel) und Single-Core Performanz - geht hervor, dass der MSOC-Algorithmus 2% weniger Dreiecke als der HiZ wegwirft, aber dennoch eine bessere Performanz erzielt [3]. Mit beiden Occlusion Culling Algorithmen kann eine 1,5-7x schnellere Total Frame Time gegenüber Rendering mit nur Frustum Culling erreicht werden. In einem zweiten Test in einer wesentlich komplexeren Szene mit 143k Occluder-Meshes ist die Occlusion Culling Time des MSOC-Algorithmus zeitweise bis zu 10x schneller als die des HiZ-Algorithmus [3]. Die Skalierbarkeit des MSOC ist der des HiZ deutlich überlegen. Mit steigender Größe der Dreiecke steigt auch der Performanzunterschied zwischen dem MSOC und dem HiZ. Im Allgemeinen soll der MSOC-Algorithmus 3x schneller sein und gleichzeitig 98% aller Dreiecke wegwerfen als die bisherigen Algorithmen bei einem nur geringen Memory Overhead [3].



Abb. 4. Links: Menge der Occluder ohne Occludees, die in dieser Kameraeinstellung zu sehen sind, vgl. Abb. 1 linkes Bild. Rechts: Testszene ohne Occluder, es sind ausschließlich Occludees zu sehen, vgl. ebenfalls Abb. 1.

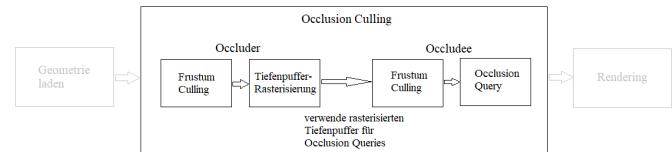


Abb. 5. SOC-Ablauf: Nach Laden der Occludermenge wird im ersten Schritt durch Rasterisieren der Occluder der Tiefenpuffer generiert. Im zweiten Schritt werden die Occlusion Queries gestartet, die durch Rasterisierung und Tiefentests bestimmen, welche Objekte der Occludee-Menge sichtbar sind und welche nicht. Die Ergebnismenge wird an den Renderer weitergeleitet.

## 3 SOFTWARE OCCLUSION CULLING

Die Menge der Objekte, die es zu Rendern gilt, wird in zwei Mengen aufgeteilt. Zum einen gibt es die *Occluder*. Occluder sind eine Menge von Objekten, die groß genug sind, dass es wahrscheinlich ist, dass sie andere Objekte verdecken. Zum anderen gibt es *Occludees*. Occludees sind all diejenigen Objekte die potenziell von Occludern verdeckt werden (das heißt, sie beinhalten ebenfalls alle Occluder). Sowohl Occluder als auch Occludees liegen dabei in zwei Formen vor. Einmal als Netz, bestehend aus Punkten (Mesh), das zur exakten Darstellung des Objekts in der gerenderten Szene dient und einmal in Form einer *Axis Aligned Bounding Box* (AABB), die sowohl zum Frustum Culling als auch zum (Tiefen-)Rasterisieren verwendet wird. AABBs eignen sich wegen ihrer einfachen geometrischen Form sehr gut, um erste grobe Tests durchzuführen, ob ein Objekt überhaupt von der Kamera gesehen werden kann (Frustum Culling) und dementsprechend für die folgende Rasterisierung beim Occlusion Culling in Frage kommt.

Occlusion Culling besteht im Wesentlichen aus zwei Schritten. Als erstes wird der Tiefenpuffer auf Basis einer Occludermenge beschrieben. Diese Occluder werden in einem ersten Renderingdurchlauf rasterisiert, jedoch ohne die Objekte tatsächlich zu zeichnen, und der Tiefenpuffer wird entsprechend der Occludermenge beschrieben. Schritt zwei besteht darin Occlusion Queries durchzuführen. Bei den Occlusion Queries werden die Bounding Boxen aller Occludees gegen den im vorherigen Schritt erstellten Tiefenpuffer getestet und es wird geprüft, ob die Occludees den Tiefentest bestehen oder nicht, sprich, ob die Occludees von einem Occluder komplett verdeckt werden oder (teilweise) sichtbar sind. Unmittelbar vor jedem dieser beiden Schritte wird zusätzlich noch Frustum Culling durchgeführt, um die Menge der zu testenden Objekte bereits im Vorfeld einzuschränken und somit weiter an Performanz zu gewinnen. Der grundsätzliche Ablauf in jedem Frame sieht also entsprechend Abb. 5 aus.

### 3.1 Frustum Culling

Frustum Culling lässt nur Objekte passieren, die sich im Sichtbereich der Kamera befinden und kann somit je nach Kameraposition einen großen Teil der Objekte aus der Menge der zu rendernden Objekte herausnehmen. Dafür wird die AABB des Objekts gegen jede der sechs Ebenen des Frustums getestet, ob sich die AABB *vollständig*




Abb. 6. Links: Testbild der Szene. Rechts: Der dazugehörige Tiefenpuffer, der in jedem Frame einmal berechnet wird und später für die Tiefentests der Occlusion Queries verwendet wird. Der schwarze Balken unterhalb des Tiefenpuffers entsteht durch die Differenz zwischen Fensterauflösung 1920x1200 und Tiefenpuffer-Auflösung 1920x1080.

außerhalb einer dieser Ebenen befindet. Ist das der Fall, kann das Objekt als nicht sichtbar markiert werden und wird im weiteren Verlauf nicht weiter betrachtet. Dieser Zwischenschritt ist zwar optional, ist aber den Rechenaufwand wert, denn er bringt eine enorme Leistungssteigerung von teilweise über 200%.

**(Optional! Vielleicht an anderer Stelle?)** Anmerkung zum Frustum Culling: Während die Performance des Frustum Cullings sehr konstant bleibt, sind bei anderen Occlusion Culling Algorithmen größere Schwankungen erkennbar, da ein großer Occluder im Vordergrund potenziell alle Occludees hinter ihm überdecken kann und damit die Berechnung stark vereinfacht [3].

### 3.2 Tiefenpuffer Rasterisierung

Alle Occluder, die nach dem Frustum Culling als sichtbar markiert sind, werden in diesem Schritt verwendet, um einen Tiefenpuffer zu generieren. Dazu werden alle sichtbaren Objekte als eine Occludermenge „gerendert“ (es wird lediglich ein Tiefenpuffer erzeugt ohne die Objekte tatsächlich zu zeichnen). Das Rendering rasterisiert die Occluder, das heißt, die Occluder werden auf den Bildschirm (screen space) transformiert und erzeugt anschließend den Tiefenpuffer, indem an den Stellen auf dem Bildschirm, an denen sich das Objekt befindet, die Tiefenwerte des Objekts gespeichert werden, siehe Abb. 6.

### 3.3 Occlusion Queries

An dieser Stelle sei erwähnt, dass die gesamte Occludeemenge zu Beginn des Programms einmal hochgeladen wurde (wohin?) und im Programm selber nur via Indexlisten zugegriffen wird, so dass zusätzliche Ladezeiten vermieden werden. Die Realisierung der Occlusion Queries gestaltet sich durch die von der OpenGL API zur Verfügung gestellten *glQuery* sehr unkompliziert. Zu Anfang werden für alle Occludees, die innerhalb des Frustums sind, eine Occlusion Query gestartet. Die Occludees werden wie die Occluder rasterisiert, allerdings wird in diesem Schritt der Tiefenpuffer nicht überschrieben, sondern es wird ausschließlich getestet, ob der Tiefenwert des Occludees kleiner als der des Tiefenpuffers ist. Die Occlusion Query testet also, ob ein Teil des Occludees bei einem potenziellen Renderdurchlauf sichtbar wäre. In diesem Fall liefert die Occlusion Query „true“ zurück, andernfalls „false“. Nachdem alle Occlusion Queries ihre Berechnungen beendet haben, werden zum Schluss alle Ergebnisse abgefragt und an das Framework für den weiteren Renderingverlauf weitergeleitet.

## 4 ERGEBNISSE

Die dokumentierten Ergebnisse wurden mit dem SOC-Framework von Intel berechnet und verwenden die dortige Testszene einer Burg beziehungsweise eines Marktplatzes, siehe Abb. 1. Die Burg umfasst 115 Occluder mit 48700 Dreiecken und 27025 Occludees mit  $\approx$  1923000 Dreiecken [3]. Sofern nicht anders angegeben, wurden sämtliche Ergebnisse mit einer Kamerafahrt, wie sie in Abb. 7 angedeutet ist, über 100 Frames erstellt. Der Tiefenpuffer ist standardmäßig auf eine Auflösung von 1920x1080 Pixel gesetzt und außerdem sind Multithreading, Frustum Culling und Occlusion Culling eingeschalten. Die Kamera startet mit Blick auf die Burg aus einiger Entfernung



Abb. 7. Links: Startposition der Kamerafahrt. Mitte: nähert sich in einem Kreisbogen der Brücke an. Rechts: Die Kamera verlässt die Szene in gleichem Bogen, wie sie sich angenähert hat.

und fliegt auf die Burg zu. An der Burg angekommen dreht sich die Kamera in Richtung Boden und entfernt sich anschließend wieder von der Burg. Die Anzahl der Objekte im Sichtfeld ist am Anfang sehr hoch, sinkt in der Mitte der Kamerafahrt ab und steigt am Ende wieder auf den Startwert. Als Hardware wurde ein Rechner mit einem Intel Core i9-7900X, einer NVIDIA Titan Xp und 64 GB RAM verwendet.

Zuerst wurde die OGL-Methode auf den qualitativen Aspekt untersucht, das heißt, ist das Ergebnis korrekt und wie „gut“ ist das Ergebnis im Hinblick auf die Anzahl der weggeworfenen Dreiecke. Abb. 8 zeigt die erzielten Ergebnisse. Im linken Bild ist ein Vergleich aller im SOC-Framework implementierten Occlusion Culling Techniken zu finden. Es ist gut zu sehen, dass die OGL-Methode qualitativ keinerlei Abstriche bei dieser Eigenschaften gegenüber den anderen Techniken machen muss. Lediglich die etwas schlechteren Werte der MOC-Methode stehen hervor, aber das ist nicht verwunderlich, da dies bereits in [3] erläutert wurde. In einem weiteren Test, der nur die OGL-Methode betrifft, wurde untersucht, inwiefern eine geringere Auflösung des Tiefenpuffers Auswirkungen auf die Anzahl der weggeworfenen Dreiecke hat und somit indirekt ebenfalls Auswirkungen auf die Anzahl der Objekte, die weggeworfen werden und schließlich auf die Anzahl der Draw Calls, die einen wichtigen Teil der gesamten Performanz ausmachen. Die Ergebnisse sind größtenteils genau so zu erwarten. Je geringer die Auflösung des Tiefenpuffers wird, desto größer und ungenauer wird das Ergebnis, sprich mit fallender Auflösung steigt die Anzahl der Dreiecke, die weggeworfen werden. Interessant ist das Ergebnis für die Auflösung 2432x1440. Zu Anfang ist der Verlauf ähnlich zu allen anderen, aber etwa ab Frame 60 verringert sich die Anzahl an weggeworfenen Dreiecken ungefähr linear und nicht wie allen anderen ungefähr quadratisch. **ERKLÄRUNG DAFÜR.** Ebenfalls wie erwartet ist das Ergebnis für die Anzahl an Objekten, die weggeworfen werden und die Draw Calls (siehe Abb. 8 Tabelle). Geht die Anzahl der weggeworfenen Objekte hoch, geht entsprechend die Anzahl der Draw Calls runter (und darüber hinaus verbessert sich entsprechend die Performanz, später mehr). Lediglich die Anzahl an Draw Calls für 2432x1440 entrinnt dem Muster, da es erwartungsgemäß weniger Draw Calls geben müsste für die Anzahl an weggeworfenen Dreiecken.

Als nächstes wurden die Auswirkungen verschiedener Culling Kombinationen auf die Anzahl der weggeworfenen Dreiecke und vor allem auf die Draw Calls untersucht, siehe Abb. 9. Läuft die OGL-Methode ohne Frustum Culling und ohne das Ausführen der Occlusion Queries, ist die Anzahl an Draw Calls entsprechend hoch, da die Anzahl an sichtbaren Objekten durch die fehlenden Culling-Mechanismen sehr hoch ist. Interessant ist der Höhepunkt in der Mitte der Kamerafahrt. Wohingegen bei den anderen Kombinationen an dieser Stelle der niedrigste Wert erreicht wird, ist er dort ohne Frustum Culling und ohne Occlusion Queries am höchsten. Besser wird das Ergebnis, wenn zusätzlich zum Multithreading das Frustum Culling aktiviert wird. Je näher die Kamera sich der Burg nähert, desto höher ist die Anzahl weggeworfener Objekten und die Menge an Draw Calls fällt entsprechend auf ihren Tiefstwert und steigt anschließend wieder mit Distanz der Kamera zur Burg. Sind sowohl Frustum Culling als auch Occlusion Queries aktiviert, ist der Verlauf der im Prinzip der Gleiche, mit dem Unterschied, dass die Menge an Draw Calls zu Anfang und zum Schluss massiv niedriger ist. Sind es ohne Occlusion Queries zu Anfang rund 17000 Objekte, die gerendert werden müssen,




Abb. 8. Im linken Diagramm ist die Prozentangabe der weggeworfenen Dreiecke mit den fünf verschiedenen Methoden des SOC-Frameworks, bei einer Auflösung des Tiefenpuffers von 1920x1080, zu sehen. Im rechten Diagramm wird die Anzahl der weggeworfenen Dreiecke bei unserer OGL-Methode mit fünf verschiedenen Auflösungen des Tiefenpuffers verglichen. Interessant zu beobachten ist der Verlauf für die Auflösung 2432x1440, da er im abfallenden Bereich ungefähr linear und nicht annähernd quadratisch verläuft. Tabelle: Die Anzahl der Draw Calls ist bei 2432x1440 ebenfalls etwas außerhalb des Musters, vergleiche zum Beispiel mit 640x360.

so sind es mit Occlusion Queries in etwa 6000-7000 weniger, womit Occlusion Queries einen enormen Renderingaufwand einsparen.

#### Vergleich mit MOC fehlt noch.

Als letztes wurde der wohl wichtigste Aspekt untersucht, die Performanz im Vergleich mit anderen SOC-Methoden im Intel-Framework. Trotz der guten Werte, die die OGL-Methode in den Tests davor erzielt, schneidet sie im Leistungsstest sehr schlecht ab. Getestet wurden alle Methoden mit aktiviertem Multithreading, Frustum Culling und Tiefentest Culling. Abb. 10 zeigt den Leistungsvergleich mit den anderen SOC-Methoden. Es ist gut zu sehen, dass die FPS bei allen Methoden im Bereich circa zwischen Frame 35 und 55 stark anstiegen sind. In diesem Bereich werden mehr Objekte weggeworfen und die Anzahl an Draw Calls verringert sich, deswegen sind dort mehr FPS möglich. Ebenfalls deutlich zu erkennen ist, dass die OGL-Methode viel weniger FPS während der gesamten Fahrt hat als alle anderen. Wohingegen sich der Rest zu Beginn und gegen Ende um die  $20 \pm 5$  FPS befindet, ist die OGL-Methode bei circa 2-3 FPS anzutreffen. Ein ähnliches Bild ergibt die Analyse der Spitzenwerte. Der Maximalwert bei OGL ist bei knapp unter 10 FPS, während sich die anderen Methoden bei circa 55 FPS aufhalten (lediglich die Scalar-Methode befindet sich nicht in diesem Spitzenbereich). Diese schlechten FPS-Werte sind nicht verwunderlich, wenn die Zeiten für das Rasterisieren und die Tiefentests in der Tabelle aus Abb. 10 betrachtet werden. So hat die OGL-Methode bei einer Auflösung von 1920x1080 mitunter Werte bis 235ms für Tiefentests und 62ms Rasterisierungszeit. Zum Vergleich, die Werte beim MOC liegen bei ungefähr 0.4ms für die Rasterisierung und <5ms für Tiefentests.

Es wurde auch ein Test durchgeführt, der das Leistungsverhalten unterschiedlicher Tiefenpuffer-Auflösungen untersucht. Im rechten Bild von Abb. 10 sind die verschiedenen Verläufe zu sehen. Je geringer die Auflösung wird, desto höher werden die Bildraten, die teilweise fast doppelt so hoch sind, wenn zum Beispiel die Anfangsphase der Kamerafahrt betrachtet wird. So kommt die Full-HD Auflösung 1920x1080, im Gegensatz zu den knapp über 4 FPS bei der sehr niedrigen Auflösung von 320x192, auf gerade einmal knapp über 2 FPS. Der Preis dafür ist allerdings ein durchaus schlechteres Ergebnis. Bei geringer Auflösung (z. B. 640x360) ist deutlich zu


erkennen, dass einige Objekte fehlen, die bei höheren Auflösungen sichtbar sind. Eine Ausnahme findet sich bei der 4k-Auflösung (3840x2160). Sie schneidet, entgegen dem Trend der niedriger werdenden FPS bei steigender Auflösung, besser ab, als die Full-HD Auflösung, trotz ihrer 4-fachen Puffergröße gegenüber Full-HD.

**Anmerkung** An dieser Stelle ist es auch im Rückblick auf Abb. 9 interessant, anzumerken, dass die Performanz am besten ist, wenn sowohl Frustum Culling als auch Tiefentest Culling deaktiviert sind. In der Standard-Kameraeinstellung werden so 12-13 FPS erreicht. Wird nur Frustum Culling aktiviert, werden so 10-11 FPS erreicht und wird zusätzlich noch das Tiefentest Culling aktiviert, fällt der Wert auf 4-5 FPS.


**Probleme** Die größten Performanzprobleme werden durch die Occlusion Queries verursacht. Das Programm wurde mit einem Performance Profiler analysiert, um herauszufinden, an welchen Stellen das Programm viel Zeit verbraucht und die meiste Zeit hält sich das Programm bei den Occlusion Queries auf. Das ist teilweise auch so zu erwarten, da die Occlusion Queries ein essentieller Teil des Programms sind. Dennoch wird dort zu viel Zeit verbracht, vor allem der Tatsache geschuldet, dass der Prozessor nicht mehr als 50% ausgelastet ist und damit nicht seine gesamte Kapazität in Anspruch nimmt. Ein Grund für den großen Zeitverlust wurde bei langen Wartezeiten gesehen, die entstanden sind, nachdem alle OQ gestartet wurden und das Programm auf die Ergebnisse warten musste. Deswegen wurde die Implementierung dahingehend geändert, dass ein zweites Set an Occlusion Queries generiert wurde, das die Ergebnisse der OQs des vorherigen Frames enthält. Durch das zweite Set kann die Warteroutine weggelassen werden, unter der Annahme, dass im aktuellen Frame alle Ergebnisse des vorherigen Frames vorliegen. Dadurch konnte das Problem mit langen Wartezeiten zwar gelöst werden, allerdings wurden dadurch keine signifikanten Performanzverbesserungen erzielt. Wieso brauchen OQ so lange?

## 5 FAZIT

In dieser Arbeit wurde gezeigt, dass es mit Hilfe von Mesa 3D möglich ist, eine Occlusion Culling Methode zu entwickeln, die parallel





	MT	MT+Frustum	MT+Frustum + Depth Test
Tries culled (%)	11.13	11.13	40.41
Draw Calls	19219	14318	10528
Models Culled	10180.34	14532.39	17903.78
Models Visible	16844.66	12492.61	9121.22



	MT	MT+Frustum	MT+Frustum + Depth Test
Tries culled (%)	11.13	11.13	43.77
Draw Calls	19219	14318	8423
Models Culled	10180.34	14532.39	19660.16
Models Visible	16844.66	12492.61	7364.84

Abb. 9. Vergleich Anzahl Draw Calls von Multi-Threading (MT), MT + Frustum Culling (FC) und MT + FC + Tiefentest Culling (TTC). Anzahl Draw Calls geht mit Verlauf der Kamerafahrt mit FC und TTC deutlich runter. Ist TTC aktiviert, werden sind die Maximalwerte am Anfang und Schluss deutlich niedriger. **Vergleich mit MOC fehlt noch**



	320x192	640x360	1280x720	1920x1080	2432x1440
FPS	21.48	17.53	9.55	4.58	5.31
DepthTest time (ms)	50.4	63.22	122.21	265.67	228.85
Rasterize time (ms)	6.64	6.85	6.87	7.07	8.02

Abb. 10. Links: FPS-Vergleich aller SOC-Methoden im Intel-Framework bei Full-HD Auflösung, aktiviertem MT, FC und TTC. OGL schneidet mit teilweise circa nur einem Fünftel der FPS von MOC oder SSE deutlich am schlechtesten ab. Rechts: Kamerafahrt mit unterschiedlichen Tiefenpuffergrößen. Mit niedriger werdenden Auflösungen sinken die Tiefentestzeiten ab (siehe Tabelle) und die FPS steigen erwartungsgemäß an, mit einer Ausnahme bei der 4k-Auflösung, die trotz ihrer 4-fachen Full-HD Puffergröße, besser abschneidet als die Full-HD Auflösung.

zum GPU-Rendering auf dem Prozessor läuft. Die Auswertung hat gezeigt, dass die neu entwickelte OGL-Methode qualitativ, im Sinne von weggeworfenen Dreiecken beziehungsweise Objekten, mit den bereits vorhandenen SOC-Methoden konkurrieren kann. Unter dem Aspekt der Performanz kann die OGL-Methode allerdings nicht mit den anderen mithalten.

**Future Work** Zukünftige Arbeiten können sich damit beschäftigen, Occludees zu Paketen zu schnüren und lediglich eine Occlusion Query mit dem Paket zu starten, anstatt wie bisher für jedes Objekt eine separate Query durchzuführen. Ziel ist es, weniger Occlusion Queries zu generieren, ohne dabei zu viel an Qualität einbüßen zu müssen und dadurch an Performanz zu gewinnen. Die Auswahl der Occludees, die zu einem Paket zusammengeschnürt werden ist dabei von großer Wichtigkeit und entscheidend für das Ergebnis, sowohl im Hinblick auf die Performanz, als auch auf die Korrektheit des Ergebnisses (werden alle Occludees angezeigt, die sichtbar sind oder fehlen Objekte in der Szene). Die Auswahl der Objekte sollte dabei so vorgenommen werden, dass nur Occludees zu einem Paket zusammengefasst werden, die sich in einer bestimmten (kleinen) Region befinden, so dass Pakete vermieden werden, bei denen die Objekte über große Teile der Szene verteilt sind. Eine erste Version dieser Technik wurde bereits implementiert und ein erster Test hat ergeben, dass eine Performanzverbesserung durchaus möglich ist, allerdings leidet das Ergebnis erheblich an Qualität, da es aktuell oft vorkommt, dass Occludee-Pakete so geschnürt werden, dass Objekte fälschlicherweise aus der Liste der zu rendernden Objekte geworfen werden. Mit einem optimierten Auswahlverfahren können auf die Weise wahrscheinlich deutliche Verbesserungen erzielt werden sowohl im Performanzbereich als auch bei der Qualität des Ergebnisses.

## LITERATUR

- [1] C. Chandrasekaran, D. McNabb, K. Kiefer, M. Fauconneau, and F. Giesen. Software occlusion culling. <https://software.intel.com/en-us/articles/software-occlusion-culling>, 2013-2016.
- [2] N. Greene, M. Kass, and G. Miller. Hierarchical z-buffer visibility. In *Proceedings of the 20th annual conference on Computer graphics and interactive techniques*, pages 231–238. ACM, 1993.
- [3] J. Hasselgren, M. Andersson, and T. Akenine-Möller. Masked Software Occlusion Culling. In U. Assarsson and W. Hunt, editors, *Eurographics/ACM SIGGRAPH Symposium on High Performance Graphics*. The Eurographics Association, 2016.